

從串接到深度： 淺層網路如何長成深層網路

彭青川

dylan0900312541@gmail.com

2026 年 9 月 6 日

摘要

本文從一個具體的問題出發：把兩個淺層 ReLU 網路首尾相接，會得到什麼？答案是一個線性區域數量遠多於任一單獨網路的函數——第二個網路的圖形被完整地複製了好幾份，其中一半左右翻轉，而複製的份數正好等於第一個網路把輸出值域來回掃過的次數。接著把串接式子展開，會發現串接所產生的權重矩陣被迫是秩為 1 的外積；把這個限制拿掉，得到的就是真正的深層網路。本文完整推導這個展開過程，改寫成矩陣記號，並一般化到 K 層與任意各層寬度，最後說明深度所換來的東西：線性區域的數量隨層數呈指數成長，而通用近似定理本身並不需要深度。

來源說明. 本文是一份讀書筆記。整體的推導脈絡、記號慣例與範例取材，均依循 Prince 所著 *Understanding Deep Learning* 第 4 章 [1]；其中內容屬於標準教材，Goodfellow 等人 [2] 亦有相近處理，線性區域數量的結果源自 Montúfar 等人 [3]。本文所有圖表皆為重新繪製，並以文中給定的參數實際計算。文中不主張任何原創研究成果，撰寫目的是把一段推導整理成作者日後可以回頭查閱的形式。

1 引言

一個具有單一隱藏層的 ReLU 網路，其輸出是輸入的分段線性函數。以純量輸入為例， D 個隱藏單元

$$h_j = a[\theta_{j0} + \theta_{j1}x], \quad j = 1, \dots, D, \quad (1)$$

其中 $a[\cdot] = \max(0, \cdot)$ 為 ReLU，再線性組合成輸出

$$y = \phi_0 + \sum_{j=1}^D \phi_j h_j. \quad (2)$$

每個單元在 $x = -\theta_{j0}/\theta_{j1}$ 處轉折，因此 D 個單元把定義域切成至多 $D+1$ 個線性區域（圖 1）。

要讓函數更複雜，最直接的想法是加寬——增加 D 。另一個想法是加深：把一個網路的輸出餵給另一個網路。本文要問的就是後者具體會發生什麼事，以及它為什麼不等於把網路加寬。

第 2 節把兩個淺層網路串接起來，並說明所得函數的形狀。第 3 節把串接的式子展開，指出其中隱藏的秩限制，並在放開這個限制之後得到深層網路。第 4 節改寫成矩陣記號，第 5 節一般化到 K 層，第 6 節討論深度帶來的效益。




圖 1 一個隱藏層、三個 ReLU 單元的淺層網路。(a) 三個單元各自在一處轉折。(b) 乘上輸出權重 ϕ_j 。(c) 相加之後得到分段線性的輸出，共有 4 個線性區域。本文之後都沿用這組參數。




圖 2 串接兩個淺層網路。(a) 第一個網路的輸出，4 個線性區域。(b) 第二個網路本身的圖形，4 個線性區域。(c) 兩者串接之後，線性區域大幅增加。

2 串接兩個淺層網路

2.1 把兩個網路接起來

取兩個各有三個隱藏單元的淺層網路。第一個網路照 (1)–(2) 把 x 映到 y ；第二個網路以 y 為輸入，

$$h'_j = a[\theta'_{j0} + \theta'_{j1}y], \quad y' = \phi'_0 + \sum_{j=1}^3 \phi'_j h'_j. \quad (3)$$

兩者接起來就得到一個從 x 到 y' 的函數（圖 4(a)）。

2.2 線性區域：複製與翻轉

串接後的函數形狀有一個很清楚的幾何解釋。第二個網路只看得到 y ，所以它對相同的 y 值一定給出相同的 y' 。而第一個網路的輸出在其值域上來回掃了好幾次：在圖 2(a) 中， x 的四個線性區域各自把 y 的值域掃過一遍，兩次遞增、兩次遞減。

於是第二個網路的圖形被複製了四份。掃描方向遞增的那兩段，複製出來的是原樣；方向遞減的那兩段，複製出來的是左右翻轉的版本，因為此時 y 是從大掃到小。段落長度不同，複製出來的份也就被壓縮或拉伸（圖 3）。




圖 3 複製與翻轉。(a) 第一個網路把 x 的四個區段各自掃過 y 的同一段值域，兩段遞增、兩段遞減。(b) 串接後的函數在對應的四個區段上，分別是第二個網路圖形的四份複製；遞減的那兩段是左右翻轉的。

計數上，若第一個網路把值域掃過 m 次，第二個網路自身有 n 個線性區域，串接後至多有 mn 個線性區域。這是相乘而不是相加，也正是加深與加寬的根本差別：加寬讓區域數線性增加，加深讓它相乘。

3 從串接網路到深層網路

3.1 串接的參數受到外積的限制

上一節的串接還不是深層網路。要看出差別，把 (3) 中的 y 用 (2) 代入並展開：

$$\begin{aligned} h'_1 &= a[\theta'_{11}y + \theta'_{10}] = a[\theta'_{11}(\phi_0 + \phi_1h_1 + \phi_2h_2 + \phi_3h_3) + \theta'_{10}] \\ &= a[\theta'_{11}\phi_1h_1 + \theta'_{11}\phi_2h_2 + \theta'_{11}\phi_3h_3 + \theta'_{11}\phi_0 + \theta'_{10}], \end{aligned} \quad (4)$$

同理

$$h'_2 = a[\theta'_{21}\phi_1h_1 + \theta'_{21}\phi_2h_2 + \theta'_{21}\phi_3h_3 + \theta'_{21}\phi_0 + \theta'_{20}], \quad (5)$$

$$h'_3 = a[\theta'_{31}\phi_1h_1 + \theta'_{31}\phi_2h_2 + \theta'_{31}\phi_3h_3 + \theta'_{31}\phi_0 + \theta'_{30}]. \quad (6)$$

三式的形狀完全一致，都是「 h_1, h_2, h_3 的線性組合再取 ReLU」。把係數重新命名，

$$\psi_{ji} = \theta'_{j1}\phi_i, \quad \psi_{j0} = \theta'_{j1}\phi_0 + \theta'_{j0}, \quad (7)$$

就得到

$$h'_j = a[\psi_{j0} + \psi_{j1}h_1 + \psi_{j2}h_2 + \psi_{j3}h_3], \quad j = 1, 2, 3. \quad (8)$$




圖 4 (a) 兩個淺層網路串接：中間被壓成單一純量 y ，導致第二層的權重矩陣被迫是秩 1 的外積。(b) 深層網路：兩層隱藏單元之間全連接，權重矩陣不受限制。

關鍵在於這些 ψ_{ji} 並不是自由的。把它們排成矩陣，

$$\Psi = \begin{bmatrix} \psi_{11} & \psi_{12} & \psi_{13} \\ \psi_{21} & \psi_{22} & \psi_{23} \\ \psi_{31} & \psi_{32} & \psi_{33} \end{bmatrix} = \begin{bmatrix} \theta'_{11} \\ \theta'_{21} \\ \theta'_{31} \end{bmatrix} \begin{bmatrix} \phi_1 & \phi_2 & \phi_3 \end{bmatrix}, \quad (9)$$

它是一個外積，因此 $\text{rank } \Psi = 1$ 。九個元素其實只由六個數字決定，而且六個之中還有一個尺度的自由度是多餘的。之所以如此，是因為中間那條路徑被壓成了單一純量 y ：所有資訊都必須擠過這個瓶頸。

3.2 放開限制

既然 (8) 已經寫成了一般的形式，不妨就讓 ψ_{ji} 取任意值，不再要求它來自外積 (9)。這一步就是深層網路：

$$h_j = a[\theta_{j0} + \theta_{j1}x], \quad j = 1, 2, 3, \quad (10)$$

$$h'_j = a\left[\psi_{j0} + \sum_{i=1}^3 \psi_{ji}h_i\right], \quad j = 1, 2, 3, \quad (11)$$

$$y' = \phi'_0 + \sum_{j=1}^3 \phi'_j h'_j. \quad (12)$$

此時 Ψ 可以是任意 3×3 矩陣，秩最高為 3。串接網路是深層網路的特例——是 Ψ 恰好退化成秩 1 的那個特例。

圖 4 把兩者畫在一起。差別在中間：串接網路的兩層之間只有一條線（經過 y ），深層網路則是每個 h_i 都直接連到每個 h'_j ，沒有瓶頸。參數量上，這一層從 6 個 (θ'_{j1} 與 ϕ_i) 變成 12 個 (3×3 的 Ψ 加上 3 個偏置)。

4 矩陣記法

把 (12) 逐式寫開會很快變得難讀，改用矩陣就清楚多了。第一層是

$$\begin{bmatrix} h_1 \\ h_2 \\ h_3 \end{bmatrix} = \mathbf{a} \begin{bmatrix} \theta_{10} \\ \theta_{20} \\ \theta_{30} \end{bmatrix} + \begin{bmatrix} \theta_{11} \\ \theta_{21} \\ \theta_{31} \end{bmatrix} x, \quad (13)$$

第二層是

$$\begin{bmatrix} h'_1 \\ h'_2 \\ h'_3 \end{bmatrix} = \mathbf{a} \begin{bmatrix} \psi_{10} \\ \psi_{20} \\ \psi_{30} \end{bmatrix} + \begin{bmatrix} \psi_{11} & \psi_{12} & \psi_{13} \\ \psi_{21} & \psi_{22} & \psi_{23} \\ \psi_{31} & \psi_{32} & \psi_{33} \end{bmatrix} \begin{bmatrix} h_1 \\ h_2 \\ h_3 \end{bmatrix}, \quad (14)$$

輸出是

$$y' = \phi'_0 + \begin{bmatrix} \phi'_1 & \phi'_2 & \phi'_3 \end{bmatrix} \begin{bmatrix} h'_1 \\ h'_2 \\ h'_3 \end{bmatrix}. \quad (15)$$

把向量與矩陣各給一個名字，整個網路就只剩三行：

$$\mathbf{h} = \mathbf{a}[\boldsymbol{\beta}_0 + \Omega_0 \mathbf{x}], \quad \mathbf{h}' = \mathbf{a}[\boldsymbol{\beta}_1 + \Omega_1 \mathbf{h}], \quad y' = \beta_2 + \Omega_2 \mathbf{h}'. \quad (16)$$

以本節的例子而言，輸入是純量、兩層各三個單元、輸出是純量，所以 $\Omega_0 \in \mathbb{R}^{3 \times 1}$ 、 $\Omega_1 \in \mathbb{R}^{3 \times 3}$ 、 $\Omega_2 \in \mathbb{R}^{1 \times 3}$ 。

值得記住的是每個 Ω_k 的角色：它乘上第 k 層的激發值，產生第 $k+1$ 層的預激發值。因此它的行數等於下一層的寬度，列數等於這一層的寬度； β_k 則是加在第 $k+1$ 層預激發值上的偏置，長度等於下一層的寬度。

5 一般化： K 層深層網路

有了 (16)，推廣到任意層數與任意寬度就只是把索引寫出來。設輸入維度為 D_i 、輸出維度為 D_o ，中間有 K 層隱藏層，第 k 層寬度為 D_k ，其激發值向量記為 $\mathbf{h}_k$ 。則

$$\begin{aligned} \mathbf{h}_1 &= \mathbf{a}[\boldsymbol{\beta}_0 + \Omega_0 \mathbf{x}], \\ \mathbf{h}_2 &= \mathbf{a}[\boldsymbol{\beta}_1 + \Omega_1 \mathbf{h}_1], \\ &\vdots \\ \mathbf{h}_K &= \mathbf{a}[\boldsymbol{\beta}_{K-1} + \Omega_{K-1} \mathbf{h}_{K-1}], \\ \mathbf{y} &= \beta_K + \Omega_K \mathbf{h}_K, \end{aligned} \quad (17)$$

其中

$$\Omega_0 \in \mathbb{R}^{D_1 \times D_i}, \quad \Omega_k \in \mathbb{R}^{D_{k+1} \times D_k} \quad (1 \leq k \leq K-1), \quad \Omega_K \in \mathbb{R}^{D_o \times D_K}, \quad (18)$$

而 β_k 的長度即為 Ω_k 的行數。整個網路寫成

$$\mathbf{f}[\mathbf{x}, \boldsymbol{\phi}], \quad \boldsymbol{\phi} = \{\boldsymbol{\beta}_k, \Omega_k\}_{k=0}^K. \quad (19)$$




圖 5 一個 $K = 3$ 的深層網路，各層寬度為 $D_i = 3$ 、 $D_1 = 4$ 、 $D_2 = 2$ 、 $D_3 = 3$ 、 $D_o = 2$ 。每個 Ω_k 的行數等於下一層寬度、列數等於本層寬度， β_k 的長度等於下一層寬度。




圖 6 (a) 純量輸入時線性區域數的上界 $(D+1)^K$ ，縱軸為對數尺度。(b) 把總參數量固定在約 471 個，對每個層數取可容納的最大寬度；標註為該層數下的寬度 D 。

圖 5 是一個具體的例子： $D_i = 3$ 、 $D_1 = 4$ 、 $D_2 = 2$ 、 $D_3 = 3$ 、 $D_o = 2$ 。沿著圖中的箭頭核對一次維度，記號就不容易記錯。參數量為

$$\underbrace{4 \times 3 + 4}_{16} + \underbrace{2 \times 4 + 2}_{10} + \underbrace{3 \times 2 + 3}_{9} + \underbrace{2 \times 3 + 2}_{8} = 43. \quad (20)$$

6 討論：深度換來什麼

第 2 節的複製與翻轉解釋了為什麼深度會讓線性區域相乘。把這個論證重複 K 次即可得到已知的結果：對純量輸入、每層 D 個 ReLU 單元、共 K 層的網路，線性區域數至多為 $(D+1)^K$ [3]。指數在層數上，底數在寬度上——這正是「深」與「寬」的差別（圖 6(a)）。

固定參數預算來比較更能看出差異。圖 6(b) 在總參數量約 471 個的限制下，對每個層數取能容納的最大寬度：一層時 $D = 156$ ，可得約 1.6×10^2 個區域；七層時每層只剩 $D = 8$ ，卻可得約 4.8×10^6 個區域。同樣的參數量，區域數差了四個數量級。

必須把話說清楚的是，這裡談的是效率而不是能力。通用近似定理說的是單一隱藏層的網路只要夠寬，就能把任意連續函數逼近到任意精度；換句話說，淺層網路在表達能力上並沒有缺口，深度並不是為了補足什麼做不到的事。深度的價值在於，同樣的參數量之下它能造出多得多的線性區域，因此對某些函數而言，達到相同精度所需的參數量少得多。

最後值得回頭看一眼第 3 節那個秩的限制。串接兩個淺層網路之所以不等於一個深層網路，唯一的原因是中間被壓成了純量瓶頸，使得權重矩陣退化成外積。把瓶頸拿掉、讓矩陣自由，就得到深層網路——從這個角度看，「深度」與其說是「疊很多層」，不如說是「不要在層與層之間設下不必要的瓶頸」。

參考文獻

- [1] S. J. D. Prince. *Understanding Deep Learning*. MIT Press, 2023. <https://udlbook.github.io/udlbook/>
- [2] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.
- [3] G. Montúfar, R. Pascanu, K. Cho, and Y. Bengio. On the number of linear regions of deep neural networks. In *Advances in Neural Information Processing Systems 27*, 2014.