

從最大似到交叉熵： 常見損失函數的統一推導

彭青川

dylan0900312541@gmail.com

2026 年 9 月 6 日

摘要

在監督式深度學習中，損失函數常被當成一種設計選擇來介紹：迴歸用平方誤差，分類用交叉熵。本文採取相反的路線，把每一個損失都視為單一原則的結果。此處不把網路看成「從輸入映射到輸出」，而是看成「從輸入映射到一個輸出機率分布的參數」。一旦在輸出的定義域上固定一個分布，並最大化訓練資料的概似，損失函數就被唯一決定了。把這個流程走過三次——分別搭配單變量常態分布、白努利分布與類別分布——即可分別得到最小平方、二元交叉熵與多類別交叉熵，同時也解釋了 sigmoid 與 softmax 函數從何而來。文中每一步推導都完整寫出，並把平常被略過的假設（固定變異數、條件獨立）明確標示出來。最後一節說明同一套流程如何延伸到沒有現成損失函數可查的輸出型態。

來源說明. 本文是一份讀書筆記。整體的推導脈絡、記號慣例，以及三個範例的取材，均依循 Prince 所著 *Understanding Deep Learning* 第 5 章 [1]；其中的內容屬於標準教材，Bishop [2] 與 Goodfellow 等人 [3] 也有相近的處理方式。本文所有圖表皆為重新繪製。文中不主張任何原創研究成果，撰寫目的是把一段推導整理成作者日後可以回頭查閱的形式。

1 引言

損失函數 $L[\phi]$ 會回傳一個數值，用以描述模型的預測 $f[x_i, \phi]$ 與實際觀測到的輸出 y_i 之間，在整個訓練集 $\{x_i, y_i\}_{i=1}^I$ 上的落差。所謂訓練，就是尋找使它最小的參數：

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} [L[\phi]]. \quad (1)$$

真正的問題是： L 從哪裡來？平方誤差是兩個實數之間合理的距離度量，交叉熵是兩個分布之間合理的分歧度量，但這樣的說法會讓它們看起來像是彼此獨立的發明，而且當輸出是比較陌生的型態時——例如計數、角度、有界的比例——就完全給不出方向。

本文採取的立場是：它們並不是彼此獨立的發明。上述三種損失全都來自同一套流程：

在輸出的定義域上選擇一個機率分布，讓網路去預測這個分布的參數，然後最小化訓練資料的負對數概似。




圖 1 模型描述的是條件機率分布 $\Pr(y|x)$ ，而不是單一輸出。在固定的輸入處（虛線）切開資料：輸出為連續時得到一條密度函數（(a) 右），輸出為離散時則得到每個類別的機率（(b) 右）。

第 2 節以這種形式建立最大概似估計，第 3 節整理出由此得到的流程。第 4 至 6 節將它分別套用在實數值、二元與類別型的輸出上。第 7 節把三個例子並列比較，並說明如何延伸到其他輸出型態。

2 最大概似

2.1 輸出上的機率分布

第一個動作，是改變我們認定網路在計算什麼。不再把輸入 x 映射到單一輸出 y ，而是讓模型針對每一個 x ，描述一個涵蓋所有可能輸出的條件機率分布 $\Pr(y|x)$ 。

圖 1 說明了這件事在後續兩種輸出型態下的意義。在連續的情形中，把資料沿著某個固定輸入垂直切下去，得到的是一條關於 y 的密度函數；在離散的情形中，同樣的一刀得到的是每個類別各自的機率。在沒有雜訊的世界裡，這些條件分布會退化成尖峰，這個區別也就沒有意義；但真實資料帶有雜訊，而條件分布的離散程度本身，正是模型可以一併學習的量。

要計算這樣的分布，只需要兩個步驟：

1. 在 y 的定義域上，選擇一個參數化的分布 $\Pr(y|\theta)$ ；
2. 用網路去計算它的一個或多個參數 θ 。

若 $y \in \mathbb{R}$ ，最自然的選擇是單變量常態分布，其參數為平均數與變異數：

$$\theta = [\mu, \sigma^2]. \quad (2)$$

值得明講的結論是：網路輸出的不再是 y 本身，而是一個關於 y 的分布的參數。

2.2 最大概似準則

對某一筆特定的輸入 x_i ，網路產生

$$\theta_i = f[x_i, \phi]. \quad (3)$$




圖 2 (a) $\log$ 為單調遞增函數。(b) 某個函數 $g[z]$ 與其負值。(c) 取 $\log$ 之後， g 的極大值位置不變（虛線）；再加上負號，該極大值就在同一個位置變成極小值。

好的 ϕ ，應該使每一筆觀測到的 y_i 在對應的分布之下都獲得高機率。把 I 筆訓練資料整體來看，要最大化的就是它們的聯合機率，也就是概似：

$$\begin{aligned}\hat{\phi} &= \operatorname{argmax}_{\phi} \left[\prod_{i=1}^I \Pr(y_i | x_i) \right] = \operatorname{argmax}_{\phi} \left[\prod_{i=1}^I \Pr(y_i | \theta_i) \right] \\ &= \operatorname{argmax}_{\phi} \left[\prod_{i=1}^I \Pr(y_i | f[x_i, \phi]) \right].\end{aligned}\quad (4)$$

把聯合機率寫成連乘，前提是資料在給定輸入之下條件獨立：

$$\prod_{i=1}^I \Pr(y_i | x_i) = \Pr(y_1, \dots, y_I | x_1, \dots, x_I). \quad (5)$$

這個假設平常很少被提起，但它在這裡確實承擔了實質的工作。

2.3 為什麼可以取對數

式 (4) 把 I 個不超過 1 的數字相乘。只要 I 稍具規模，這個乘積就會發生浮點數下溢。標準的處理方式是改用它的對數，而這麼做之所以正當，是因為 $\log$ 為單調遞增函數：

$$z' > z \implies \log[z'] > \log[z], \quad (6)$$

所以取對數會改變極大值的數值，卻不會改變它的位置（圖 2）。因此

$$\hat{\phi} = \operatorname{argmax}_{\phi} \left[\log \left[\prod_{i=1}^I \Pr(y_i | x_i) \right] \right] = \operatorname{argmax}_{\phi} \left[\sum_{i=1}^I \log[\Pr(y_i | f[x_i, \phi])] \right]. \quad (7)$$

2.4 負對數概似

最佳化的程式一律寫成求極小，因此最後一步是取負號。取負號會反轉大小關係：

$$z' > z \implies -\log[z'] < -\log[z], \quad (8)$$

所以「最大化對數概似」與「最小化負對數概似」是同一件事：

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \log [\operatorname{Pr}(y_i | f[x_i, \phi])] \right] = \underset{\phi}{\operatorname{argmin}} [L[\phi]]. \quad (9)$$

損失函數的身分到這裡就確定了： $L[\phi]$ 就是負對數概似。以下推導出來的每一個損失，都是把某個特定的分布代入 (9) 之後的結果。

2.5 推論

訓練結束後，網路回傳的仍然是一個分布。若需要一個點估計，就取機率最大的輸出：

$$\hat{y} = \underset{y}{\operatorname{argmax}} [\operatorname{Pr}(y | f[x, \hat{\phi}])]. \quad (10)$$

沒有任何理由強迫我們這樣做——完整的分布本來就在手上，直接回報它往往更有用——但這一步正是讓模型回到我們熟悉的迴歸或分類網路行為的地方。

3 建構損失函數的四個步驟

前一節的內容可以壓縮成四個步驟。

1. 在輸出的定義域上選擇一個機率分布 $\operatorname{Pr}(y | \theta)$ 。
2. 讓機器學習模型 $f[x, \phi]$ 預測它的參數 θ ；若網路未經約束的輸出落在容許範圍之外，則套上一個連結函數。
3. 尋找使負對數概似最小的參數，

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \log [\operatorname{Pr}(y_i | f[x_i, \phi])] \right]. \quad (11)$$

4. 對新的輸入 x ，回傳完整分布 $\operatorname{Pr}(y | f[x, \hat{\phi}])$ ，或式 (10) 的點估計。

接下來的三節，彼此的差別只在於步驟 1 所選的分布。

4 例一：單變量迴歸

此處 $f[x, \phi]$ 把輸入映射到單一實數， $y \in \mathbb{R}$ 。

4.1 選擇分布並預測其參數

定義域是整條實數線，因此取單變量常態分布：

$$\operatorname{Pr}(y | \theta) = \operatorname{Pr}(y | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - \mu)^2}{2\sigma^2} \right]. \quad (12)$$

先讓網路預測平均數，並暫時把變異數視為固定常數：

$$\Pr(y | f[x, \phi], \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - f[x, \phi])^2}{2\sigma^2} \right]. \quad (13)$$

也就是直接把網路的輸出當成常態分布的平均數（圖 3(c)）。這裡不需要連結函數，因為平均數本來就可以取任何實數值。

4.2 最小平方

把 (13) 代入 (9)：

$$L[\phi] = - \sum_{i=1}^I \log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y_i - f[x_i, \phi])^2}{2\sigma^2} \right] \right], \quad (14)$$

接著化簡：

$$\begin{aligned} \hat{\phi} &= \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \left(\log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \right] + \log \exp \left[-\frac{(y_i - f[x_i, \phi])^2}{2\sigma^2} \right] \right) \right] \\ &= \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \left(\log \left[\frac{1}{\sqrt{2\pi\sigma^2}} \right] - \frac{(y_i - f[x_i, \phi])^2}{2\sigma^2} \right) \right] \\ &= \underset{\phi}{\operatorname{argmin}} \left[\sum_{i=1}^I \frac{(y_i - f[x_i, \phi])^2}{2\sigma^2} \right] = \underset{\phi}{\operatorname{argmin}} \left[\sum_{i=1}^I (y_i - f[x_i, \phi])^2 \right]. \end{aligned} \quad (15)$$

第一項與 ϕ 無關：在 σ^2 固定的前提下，它的總和是 $-I \log[1/\sqrt{2\pi\sigma^2}]$ ，一個固定的偏移量。它會平移損失的數值，卻不會移動極小值的位置，因此可以丟掉；同理，正的比例因子 $1/2\sigma^2$ 也可以丟掉。剩下的就是

$$L[\phi] = \sum_{i=1}^I (y_i - f[x_i, \phi])^2, \quad (16)$$

也就是最小平方準則。這段推導讓「隨手寫下平方誤差」背後的承諾浮現出來：它假設雜訊是可加的、服從常態分布，而且——因為 σ^2 被固定住了——在每一個輸入處的離散程度都相同。

4.3 推論

常態分布的最大值出現在平均數處，因此由 (10) 得到

$$\hat{y} = \underset{y}{\operatorname{argmax}} [\Pr(y | f[x, \hat{\phi}], \sigma^2)] = f[x, \hat{\phi}] = \mu. \quad (17)$$

網路的輸出本身就是預測值。這也是為什麼在一般的迴歸實務中，「模型其實是一個分布」這件事完全看不出來：對這個特定的分布而言，兩者恰好重合。




圖 3 單變量迴歸的最小平方。(a) 殘差（灰線）很小的拟合。(b) 不良的拟合，同樣的殘差變得很大。(c) 模型在每個輸入處其實是一個以 $f[x, \phi]$ 為中心的常態分布，拟合線就是它的平均數。

4.4 估計變異數

σ^2 並沒有非固定不可的理由。把它也當成待學參數，對兩者一起最小化負對數概似，會得到熟悉的估計式

$$\hat{\sigma}^2 = \frac{1}{I} \sum_{i=1}^I (y_i - f[x_i, \hat{\phi}])^2, \quad (18)$$

也就是殘差平方的平均。拟合線決定分布的中心，殘差的離散程度則決定它的寬窄。

4.5 異質變異數迴歸

用單一個全域的 σ^2 ，等於斷言模型在任何地方的不確定性都一樣大，這通常不成立。若要讓不確定性隨輸入變化，網路就必須產生兩個輸出而不是一個（圖 4）：

$$\mu = f_1[x, \phi], \quad \sigma^2 = f_2[x, \phi]^2, \quad (19)$$

其中的平方是一個連結函數，用來保證變異數為正。損失函數由同樣的代入方式得到：

$$\hat{\phi} = \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \left(\log \left[\frac{1}{\sqrt{2\pi f_2[x_i, \phi]^2}} \right] - \frac{(y_i - f_1[x_i, \phi])^2}{2 f_2[x_i, \phi]^2} \right) \right]. \quad (20)$$

這時正規化項再也不能丟掉：它現在與 ϕ 有關，而且正是它擋住了模型把預測變異數壓到零的傾向。

5 例二：二元分類

現在要把輸入指派到兩個類別之一， $y \in \{0, 1\}$ 。

5.1 選擇分布並預測其參數

定義在 $\{0, 1\}$ 上的分布是白努利分布，只有單一參數 $\lambda = \Pr(y = 1)$ ：

$$\Pr(y | \lambda) = \begin{cases} 1 - \lambda, & y = 0, \\ \lambda, & y = 1, \end{cases} \quad \text{等價地} \quad \Pr(y | \lambda) = (1 - \lambda)^{1-y} \lambda^y. \quad (21)$$




圖 4 同質變異數與異質變異數迴歸。(a, b) 只有一個輸出時，網路只預測平均數，其周圍的區間在任何地方都一樣寬。(c, d) 有兩個輸出時，網路同時預測平均數與標準差，區間便會在模型有把握之處收窄、在沒有把握之處變寬。

右邊的合併寫法是整段推導得以進行的關鍵：沒有發生的那個類別，其因子會塌縮成 1，接著取對數就能把兩種情形拆成一個和。

參數必須滿足 $\lambda \in [0, 1]$ ，但網路輸出 $f[x, \phi]$ 是任意實數。因此需要一個連結函數，而 logistic sigmoid 是標準選擇（圖 5(a)）：

$$\lambda = \text{sig}[f[x, \phi]] = \frac{1}{1 + \exp[-f[x, \phi]]}, \quad (22)$$

於是

$$\Pr(y | \lambda) = \left(1 - \text{sig}[f[x, \phi]]\right)^{1-y} \cdot \text{sig}[f[x, \phi]]^y. \quad (23)$$

5.2 二元交叉熵

把 (23) 代入 (9)，並為了簡潔記 $s_i = \text{sig}[f[x_i, \phi]]$ ：

$$\begin{aligned} \hat{\phi} &= \underset{\phi}{\text{argmin}} \left[- \sum_{i=1}^I \log[(1 - s_i)^{1-y_i} \cdot s_i^{y_i}] \right] \\ &= \underset{\phi}{\text{argmin}} \left[- \sum_{i=1}^I \left(\log(1 - s_i)^{1-y_i} + \log s_i^{y_i} \right) \right] \\ &= \underset{\phi}{\text{argmin}} \left[- \sum_{i=1}^I \left((1 - y_i) \log(1 - s_i) + y_i \log s_i \right) \right] \end{aligned}$$




圖 5 二元分類。(a) logistic sigmoid 把實數線映射進 $[0, 1]$ 。(b) 網路的原始輸出未受約束。(c) 經過 sigmoid 之後，它成為合法的白努利參數 $\lambda[x]$ 。(d) 在固定的輸入處 ((c) 中的虛線)，模型是一個涵蓋兩個類別的分布。

$$= \underset{\phi}{\operatorname{argmin}} \left[\sum_{i=1}^I \left((y_i - 1) \log(1 - s_i) - y_i \log s_i \right) \right], \quad (24)$$

也就是

$$L[\phi] = \sum_{i=1}^I \left[(y_i - 1) \log(1 - \text{sig}[f[x_i, \phi]]) - y_i \log(\text{sig}[f[x_i, \phi]]) \right], \quad (25)$$

即二元交叉熵損失。對每一筆訓練資料而言，兩項之中只有一項有作用，而它所施加的懲罰，正比於模型指派給實際發生的那個類別的負對數機率。

6 例三：多類別分類

最後，要把輸入指派到 $K > 2$ 個類別之一， $y \in \{1, 2, \dots, K\}$ 。

6.1 選擇分布並預測其參數

此處的分布是類別分布，每個類別各有一個參數 $\text{Pr}(y = k) = \lambda_k$ 。要預測 K 個參數，網路就需要 K 個輸出：

$$f[x, \phi] = \begin{bmatrix} f_1[x, \phi] \\ f_2[x, \phi] \\ \vdots \\ f_K[x, \phi] \end{bmatrix} \in \mathbb{R}^K, \quad (26)$$

而它們必須被映射到機率單體上：

$$\sum_{k=1}^K \lambda_k = 1, \quad 0 \leq \lambda_k \leq 1. \quad (27)$$




圖 6 $K=3$ 的多類別分類。(a) K 個網路輸出是未受約束的實數函數。(b) softmax 把它們映射成類別機率，在每一個輸入處都非負且總和為 1。(c) 在固定的輸入處，模型是一個類別分布。

softmax 函數做的正是這件事：

$$\text{softmax}_k[z] = \frac{\exp[z_k]}{\sum_{k'=1}^K \exp[z_{k'}]}, \quad (28)$$

其中指數保證每一項為正，分母則保證總和為 1。它是 sigmoid 在多類別情形下的推廣，並且在 $K=2$ 時退化回 sigmoid。因此模型為

$$\Pr(y=k|x) = \text{softmax}_k[f[x, \phi]]. \quad (29)$$

6.2 多類別交叉熵

把 (29) 代入 (9)：

$$\begin{aligned} \hat{\phi} &= \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \log [\text{softmax}_{y_i}[f[x_i, \phi]]] \right] \\ &= \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \log \left(\frac{\exp[f_{y_i}[x_i, \phi]]}{\sum_{k'=1}^K \exp[f_{k'}[x_i, \phi]]} \right) \right] \\ &= \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \left(\log \exp[f_{y_i}[x_i, \phi]] - \log \left[\sum_{k'=1}^K \exp[f_{k'}[x_i, \phi]] \right] \right) \right] \\ &= \underset{\phi}{\operatorname{argmin}} \left[- \sum_{i=1}^I \left(f_{y_i}[x_i, \phi] - \log \left[\sum_{k'=1}^K \exp[f_{k'}[x_i, \phi]] \right] \right) \right], \end{aligned} \quad (30)$$

於是

$$L[\phi] = - \sum_{i=1}^I \left(f_{y_i}[x_i, \phi] - \log \left[\sum_{k'=1}^K \exp[f_{k'}[x_i, \phi]] \right] \right), \quad (31)$$

表 1 同一套流程套用在三種輸出型態上。

輸出定義域	分布	網路預測	連結函數	得到的損失
$y \in \mathbb{R}$	常態分布	μ (與 σ^2)	恆等	最小平方
$y \in \{0, 1\}$	白努利分布	λ	sigmoid	二元交叉熵
$y \in \{1, \dots, K\}$	類別分布	$\lambda_1, \dots, \lambda_K$	softmax	多類別交叉熵

即多類別交叉熵損失。分子中 $\log$ 與 $\exp$ 的相消，正是讓損失最後只用網路原始輸出來表達的原因；剩下的那一項就是 $\log\text{-sum-exp}$ ，也正是實作上必須用「減去最大值」的技巧才能穩定計算的地方。

在推論階段，由於 softmax 對每個 f_k 都是單調的，

$$\hat{y} = \operatorname{argmax}_k [\operatorname{softmax}_k [f[x, \hat{\phi}]]] = \operatorname{argmax}_k [f_k[x, \hat{\phi}]], \quad (32)$$

因此若只是要得到類別預測，softmax 根本不必計算。

7 討論

表 1 把三個例子並排列出。它們的差異只在第一欄的選擇，其餘全都是隨之而來的結果。

有兩件事值得單獨提出來說。

第一，連結函數不是經驗法則湊出來的。sigmoid 與 softmax 之所以出現，是因為網路的輸出未受約束，而白努利或類別分布的參數卻有約束；任何一個映射到容許集合上的光滑滿射都能勝任，這兩個只是慣用的選擇。把它們讀成「壓縮函數」，反而遮蔽了它們真正要滿足的那個約束。

第二，這套流程並不止於上表中的三種情形。若遇到一個沒有現成損失函數可查的輸出型態——計數、角度、落在 $(0, 1)$ 的比例、或非負的持續時間——就選一個支撐集落在該定義域上的分布（Poisson、von Mises、beta、gamma），決定要讓網路預測其中哪些參數，套上連結函數讓它們保持合法，然後寫下負對數概似。損失函數於是被「決定」出來，而不是被「設計」出來。事實上，把同一套程序套用在變異數隨網路變動的常態分布上，如第 4.5 節所示，得到的就已經是一個不在標準清單裡的損失函數了。

參考文獻

- [1] S. J. D. Prince. *Understanding Deep Learning*. MIT Press, 2023. <https://udlbook.github.io/udlbook/>
- [2] C. M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [3] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.